

Analyse de CartPole-v1

Alex Maloigne et Kamel Nehlil

1 Analyse de CartPole-v1

Nous avons 4 courbes. En bleu clair, DQN en observation partielle sans x point et θ point. En orange, DQN partiellement observé avec en mémoire la valeur précédente de x . En bleu foncé, DQN partiellement observé avec, cette fois-ci, en mémoire la valeur précédente de θ . Et pour finir, en rouge où DQN à en mémoire x et θ .




Figure 1: Valeur moyenne des q valeurs

Ici on peut voir que les q valeurs augmentent plus vite quand on a une mémoire pour deviner les observations que sans. Aussi comme l'objectif CartPole-V1 repose plus sur la stabilisation de θ et non de x , le paramètre θ est

plus utile en mémoire que x , les q values indiquent une plus grande facilité à augmenter la reward. L'observation des 2 paramètres permettent de facilement résoudre le problème du monde partiellement observable en sachant qu'on apprend les 2 paramètres manquants.




Figure 2: Valeur moyenne des rewards

Comme vu dans le graphique ci-dessus, les résultats diffèrent énormément. Dans un 1^{er} temps, la courbe sans mémoire est assez constante après avoir atteint environ 40/500 de reward. Ensuite, la courbe avec en mémoire x permet d'augmenter fortement la valeur de la reward, en étant autour des 250/500, mais elle est peu stable et stagne entre 100 et 200 après une plutôt longue période. En revanche, les courbes avec toute la mémoire et seulement θ en mémoire sont meilleurs. En effet, elles atteignent des résultats parfait ou proche de la perfection en moyenne (498 et 500 respectivement). Cependant, on voit une tendance de stabilisation pour la courbe rouge avec au début une forte croissance. La courbe bleue foncée possède quant à elle beaucoup plus d'outliers et est moins stable. Elle est aussi en moyenne moins efficace que la courbe rouge.




Figure 3: Valeur max des rewards




Figure 4: Valeur min des rewards

Les figures 3 et 4 nous en montrent un peu plus. En effet, on constate que les valeurs maximales de la reward sont facilement atteignables par les courbes avec de la mémoire même si les courbes avec θ en mémoire sont meilleurs que celle avec seulement x . Par contre, avoir spécifiquement θ en mémoire permet d'augmenter la reward minimum et de minimiser les pertes, ce qui devrait faciliter l'apprentissage plus vite au début.