

Analyse de CartPole-v1

Alex Maloigne et Kamel Nehlil

1 Analyse de CartPole-v1

Nous avons 4 courbes. En bleu clair, DQN en observation partielle sans x point et θ point. En orange, DQN partiellement observé avec en mémoire la valeur précédente de x . En bleu foncé, DQN partiellement observé avec, cette fois-ci, en mémoire la valeur précédente de θ . Et pour finir, en rouge où DQN à en mémoire x et θ .




Figure 1: Valeur moyenne des q valeurs

Ici on peut voir que les q valeurs augmentent plus vite quand on a une mémoire pour deviner les observations que sans. Aussi comme l'objectif CartPole-V1 repose plus sur la stabilisation de θ et non de x , le paramètre θ est

plus utile en mémoire que x , les q values indiquent une plus grande facilité à augmenter la reward. L'observation des 2 paramètres permettent de facilement résoudre le problème du monde partiellement observable en sachant qu'on apprend les 2 paramètres manquants.




Figure 2: Valeur moyenne des rewards

Comme vu dans le graphique ci-dessus, les résultats diffèrent énormément. Dans un 1^{er} temps, la courbe sans mémoire est assez constante après avoir atteint environ 40/500 de reward. Ensuite, la courbe avec en mémoire x permet d'augmenter fortement la valeur de la reward, en étant autour des 250/500, mais elle est peu stable et stagne entre 100 et 200 après une plutôt longue période. En revanche, les courbes avec toute la mémoire et seulement θ en mémoire sont meilleurs. En effet, elles atteignent des résultats parfait ou proche de la perfection en moyenne (498 et 500 respectivement). Cependant, on voit une tendance de stabilisation pour la courbe rouge avec au début une forte croissance. La courbe bleue foncée possède quant à elle beaucoup plus d'outliers et est moins stable. Elle est aussi en moyenne moins efficace que la courbe rouge.




Figure 3: Valeur max des rewards




Figure 4: Valeur min des rewards

Les figures 3 et 4 nous en montrent un peu plus. En effet, on constate que les valeurs maximales de la reward sont facilement atteignables par les courbes avec de la mémoire même si les courbes avec θ en mémoire sont meilleurs que celle avec seulement x . Par contre, avoir spécifiquement θ en mémoire permet d'augmenter la reward minimum et de minimiser les pertes, ce qui devrait faciliter l'apprentissage plus vite au début.

2 Analyse de l'Action Wrapper sur CartPole-v1

Dans cette partie, nous allons expérimenter avec l'Action Wrapper et ses effets potentiels positifs. Nous testerons trois scénarios différents: sans wrapper supplémentaire, avec les vitesses cachées et une mémoire sur x , et enfin le dernier scénario qui est similaire au précédent, mais avec une mémoire sur θ . La valeur de l'Action Wrapper est fixée à 5 actions dans le futur.

2.1 Sans autre wrapper

Ce cas est le moins intéressant, mais constitue un bon début pour observer d'éventuelles tendances avantageuses.




Figure 5: Valeur max des q values

Ici, c'est très intéressant : on observe que les valeurs Q maximales sont beaucoup plus élevées avec l'Action Wrapper qu'en l'absence de celui-ci. Cela signifie que, lors du choix des valeurs Q , il y a moins de chances d'obtenir une valeur faible, et donc un mauvais choix.




Figure 6: Valeur max des rewards

On observe que les valeurs de récompense sont globalement similaires, ce qui peut s'expliquer par la capacité de l'algorithme DQN à obtenir facilement de bons résultats dans l'environnement de base. Toutefois, les récompenses obtenues avec l'Action Wrapper sont souvent légèrement supérieures. En fin d'entraînement, on constate que les versions avec wrappers surpassent généralement l'absence de wrapper. Cependant, de manière surprenante, l'action wrapper avec le paramètre 5 devient moins performant que les autres, atteignant un niveau comparable à celui sans wrapper.

2.2 Monde partiellement observable sans mémoire

Ce cas est censé présenter les résultats les plus chaotiques et équilibrés, car l'algorithme DQN a généralement peu de difficulté à bien s'adapter à cet environnement.




Figure 7: Valeur max des q values

On observe de manière un peu désordonnée que les q values sont globalement équivalentes.




Figure 8: Valeur max des q values

On peut toutefois remarquer que les rewards sont meilleures lorsque le niveau de l'Action Wrapper augmente, ce qui montre qu'il reste efficace malgré des Q-values très chaotiques.

2.3 Mémoire sur x

Ce cas est bien plus intéressant que le précédent. On reprend le cas précédent, mais en y ajoutant une mémoire sur la donnée x , ce qui rend possible le calcul de sa dérivée temporelle $\dot{x}$.




Figure 9: Valeur max des q values

On observe que les Q-values augmentent avec le niveau de l'Action Wrapper.




Figure 10: Valeur max des rewards

SL'analyse du graphe montre une augmentation globale des récompenses, notamment pour les niveaux 4 et 5 de l'Action Wrapper. Cependant, ces récompenses tendent à se stabiliser autour de 250 en fin d'apprentissage.

2.4 Mémoire sur θ

Ceci ressemble beaucoup au dernier cas et permet de valider nos hypothèses. En effet, ce cas est le plus intéressant car il impacte la donnée la plus importante avec l'Action Wrapper, θ qui permet de calculer $\hat{\theta}$.




Figure 11: Valeur max des q values

On observe que les Q-values s'améliorent à mesure que l'Action Wrapper augmente. Toutefois, avec un niveau de 5, elles restent inférieures à celles du niveau 4, avant de rattraper ce retard en fin d'entraînement. Les niveaux 2 et 3 semblent quasiment équivalents à l'apprentissage sans l'Action Wrapper.




Figure 12: Valeur max des rewards

On observe que les récompenses avec l'Action Wrapper sont supérieures à celles obtenues sans, mais lorsqu'on les compare entre elles, les différences restent minimes. On remarque simplement que les niveaux 3 et 4 augmentent plus rapidement que les niveaux 2 et 5, bien qu'ils atteignent rapidement un niveau équivalent. En fin d'entraînement, toutes les configurations semblent converger vers des résultats similaires.

2.5 Conclusion

En conclusion, l'Action Wrapper améliore considérablement les performances de l'algorithme en augmentant les Q-valeurs, en offrant de meilleures récompenses. Il permet ainsi à l'algorithme de prendre des décisions plus judicieuses et d'optimiser ses choix d'actions sur CartPole.