

Analyse de CartPole-v1

Alex Maloigne et Kamel Nehlil

1 Analyse de CartPole-v1

Nous avons 4 courbes. En bleu clair, DQN en observation partielle sans x point et θ point. En orange, DQN partiellement observé avec en mémoire la valeur précédente de x . En bleu foncé, DQN partiellement observé avec, cette fois-ci, en mémoire la valeur précédente de θ . Et pour finir, en rouge où DQN à en mémoire x et θ .




Figure 1: Valeur moyenne des q valeurs

Ici on peut voir que les q valeurs augmentent plus vite quand on a une mémoire pour deviner les observations que sans. Aussi comme l'objectif CartPole-V1 repose plus sur la stabilisation de θ et non de x , le paramètre θ est

plus utile en mémoire que x , les q values indiquent une plus grande facilité à augmenter la reward. L'observation des 2 paramètres permettent de facilement résoudre le problème du monde partiellement observable en sachant qu'on apprend les 2 paramètres manquants.




Figure 2: Valeur moyenne des rewards

Comme vu dans le graphique ci-dessus, les résultats diffèrent énormément. Dans un 1^{er} temps, la courbe sans mémoire est assez constante après avoir atteint environ 40/500 de reward. Ensuite, la courbe avec en mémoire x permet d'augmenter fortement la valeur de la reward, en étant autour des 250/500, mais elle est peu stable et stagne entre 100 et 200 après une plutôt longue période. En revanche, les courbes avec toute la mémoire et seulement θ en mémoire sont meilleurs. En effet, elles atteignent des résultats parfait ou proche de la perfection en moyenne (498 et 500 respectivement). Cependant, on voit une tendance de stabilisation pour la courbe rouge avec au début une forte croissance. La courbe bleue foncée possède quant à elle beaucoup plus d'outliers et est moins stable. Elle est aussi en moyenne moins efficace que la courbe rouge.




Figure 3: Valeur max des rewards




Figure 4: Valeur min des rewards

Les figures 3 et 4 nous en montrent un peu plus. En effet, on constate que les valeurs maximales de la reward sont facilement atteignables par les courbes avec de la mémoire même si les courbes avec θ en mémoire sont meilleurs que celle avec seulement x . Par contre, avoir spécifiquement θ en mémoire permet d'augmenter la reward minimum et de minimiser les pertes, ce qui devrait faciliter l'apprentissage plus vite au début.

2 Analyse de l'Action Wrapper sur CartPole-v1

Dans cette partie, nous allons expérimenter avec l'Action Wrapper et ses effets potentiels positifs. Nous testerons trois scénarios différents: sans wrapper supplémentaire, avec les vitesses cachées et une mémoire sur x , et enfin le dernier scénario qui est similaire au précédent, mais avec une mémoire sur θ . La valeur de l'Action Wrapper est fixée à 5 actions dans le futur.

2.1 Sans autre wrapper

Ce cas est le moins intéressant, mais constitue un bon début pour observer d'éventuelles tendances avantageuses. Les courbes bleues sont l'Action Wrapper et les courbes oranges sont l'environnement classique.




Figure 5: Moyenne des q valeurs

Il y a peu à dire, on constate que les valeurs Q sont généralement équivalentes, bien que l'Action Wrapper soit légèrement meilleur.




Figure 6: Min des q valeurs

Ici, c'est très intéressant : on observe que les valeurs Q minimales sont beaucoup plus élevées avec l'Action Wrapper qu'en l'absence de celui-ci. Cela signifie que, lors du choix des valeurs Q , il y a moins de chances d'obtenir une valeur faible, et donc un mauvais choix.




Figure 7: Valeur moyenne des rewards

On constate que les valeurs de reward sont équivalentes, ce qui peut s'expliquer par le fait que l'algorithme DQN parvient facilement à obtenir de bons résultats dans l'environnement de base.




Figure 8: Valeur min des rewards

On remarque que les récompenses minimales sont, en revanche, un peu meilleures avec l'Action Wrapper après un certain temps d'apprentissage. On peut donc supposer que l'on fait de meilleurs choix avec l'Action Wrapper, bien que cela ne soit pas encore certain.

2.2 Mémoire sur x

Ce cas est beaucoup plus intéressant que le précédent. La courbe rouge représente les résultats sans l'Action Wrapper, tandis que la courbe bleu clair montre ceux avec l'Action Wrapper.




Figure 9: Moyenne des q valeurs

On observe que, en moyenne, les valeurs Q sont beaucoup plus élevées. Cela signifie que l'algorithme fait de meilleurs choix lorsqu'il prend en compte plusieurs actions dans le futur.




Figure 10: Moyenne des rewards

On observe des récompenses bien plus élevées avec l'Action Wrapper qu'en son absence. Cela démontre que les Q -valeurs supérieures ont effectivement un effet positif et que l'objectif de l'Action Wrapper est atteint.




Figure 11: Max des rewards




Figure 12: Min des rewards

On observe une valeur maximale et une valeur minimale des récompenses bien plus importantes avec l'Action Wrapper. Cela permet d'assurer que, au pire comme au mieux, les actions sont bien meilleures qu'en l'absence de l'Action Wrapper.

2.3 Mémoire sur θ

Ceci ressemble beaucoup au dernier cas et permet de valider nos hypothèses. En effet, ce cas est le plus intéressant car il impacte la donnée la plus importante avec l'Action Wrapper, θ . La courbe verte représente l'Action Wrapper, tandis que la courbe rose montre les résultats sans l'Action Wrapper.




Figure 13: Moyenne des q valeurs

Comme précédemment avec x , on remarque que la moyenne des Q-valeurs est systématiquement plus élevée avec l'Action Wrapper.




Figure 14: Moyenne des rewards

La valeur moyenne des récompenses suit la tendance des Q-valeurs, ce qui prouve que l'Action Wrapper permet un meilleur choix d'action.




Figure 15: Max des rewards




Figure 16: Min des rewards

Les valeurs maximales et minimales des récompenses sont également bien meilleures avec l'Action Wrapper, ce qui permet d'éviter des résultats nuls en général. Cette amélioration indique que l'algorithme est plus stable et plus efficace dans ses choix d'actions.

2.4 Conclusion

En conclusion, l'Action Wrapper améliore considérablement les performances de l'algorithme en augmentant les Q-valeurs, en offrant de meilleures récompenses moyennes, et en réduisant les risques de résultats faibles ou nuls. Il permet ainsi à l'algorithme de prendre des décisions plus judicieuses et d'optimiser ses choix d'actions sur CartPole.